

Trabajo 2 Series

Autores:

- Juan Pablo Aldana Henao
- Jorge Andres Sanchez Duarte
- Daniel Mauricio Vanegas Oliveros

Introducción a Datos

Este conjunto de datos es diferente al del trabajo anterior ya que al ser una serie bursátil, las cuales son difíciles de trabajar en esta área de Series de Tiempo; de esta manera, decidimos cambiarlo por una serie de tiempo extraída de [Kaggle](#), la cual a su vez es extraída de **Federal Reserve Bank of St.Louis (FRED)** (para origen de la información, revisar referencias al final del documento), en la que se muestra la producción energética (tanto eléctrica como de gas) mensual de los EEUU entre el primer mes de 1985 y 2025, conformándose de 480 observaciones que nos permitirán trabajar modelos SARIMA.

Las observaciones corresponden al **Índice IPG2211A2N**, este índice hace parte del índice de producción industrial de EEUU, midiendo la producción real (no ingresos) combinada entre los sectores públicos eléctricos y de gas. Estos son reportes (observaciones) mensuales. La propia **FRED** señala que estos datos explican la mayor parte de la economía estadounidense (esto porque existe una correlación fuerte entre consumo eléctrico y PIB). El índice tiene su metodología de construcción que pondera los cambios en producción según el aporte y valor agregado de cada sector; las mediciones se realizan mediante variables cuantitativas consideradas como kWh (producción de electricidad) o volumen de gas. En caso de datos faltantes usan variables relacionadas para su estimación e imputación (denominadas por ellos como variables proxys).


Ahora, es de hacerse notar que la serie transcurre en períodos significativamente importantes para la economía estadounidense, particularmente el 2008 en el que ocurrió la crisis financiera y la pandemia de 2020. Para evitar problemas de estimación (con los que nos encontramos al trabajar la serie desde 1985 hasta 2025) decidimos tomar en cuenta un período de 20 años, es decir 240 meses entre 1985 y 2005, que sería un período sin tantos eventos significativos para la economía estadounidense (salvo los atentados del 11 de septiembre de 2001) pero con suficiente cantidad de datos para hallar estacionalidad.

El objetivo de este trabajo es identificar modelos estacionales capaces de explicar series de tiempo con una considerable cantidad de observaciones, a su vez de verificar la necesidad sobre modelos más complejos para obtener mejores estimaciones.

En el siguiente gráfico se puede apreciar el comportamiento total de la serie:

```
plot.ts(serie, main = "Gráfico de la Serie", xlab = "Meses", ylab = "Producción Eléctrica")
```


Gráfico de la Serie




Y a continuación podemos apreciar ambos Autocorrelograma y Autocorrelograma Parcial:

```
par(mfrow = c(1,2))  
acf(serie, main = "Autocorrelograma")  
pacf(serie, main = "Autocorrelograma Parcial")
```

Autocorrelograma



Autocorrelograma Parcial



```
par(mfrow = c(1,1))
```

Desde los cuales ya podemos sospechar la presencia de estacionalidad en el gráfico de autocorrelograma. Note particularmente que el decimotercer mes está bajo la autocorrelación parcial negativa y significativa; ello implicaría que la producción eléctrica está ligada a la de un año inmediatamente anterior. De esta forma, se podrían considerar dos modelos; uno que sea el indicado directamente por el comando **auto.arima** y otro bajo este comportamiento anual de la serie. Ahora procedemos a revisar la estacionariedad de la misma bajo diferentes transformaciones:

```
adf.test(serie)
```

Augmented Dickey-Fuller Test

```
data: serie
Dickey-Fuller = -7.5397, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

```
adf.test(log(serie))
```

Augmented Dickey-Fuller Test

```
data: log(serie)
Dickey-Fuller = -6.5926, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

```
adf.test(diff(serie))
```

Augmented Dickey-Fuller Test

```
data: diff(serie)
Dickey-Fuller = -6.7998, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

```
adf.test(diff(log(serie)))
```

Augmented Dickey-Fuller Test

```
data: diff(log(serie))
Dickey-Fuller = -6.9765, Lag order = 6, p-value = 0.01
alternative hypothesis: stationary
```

De lo que podemos concluir que en general no será una serie que nos implique problemas para trabajar bajo modelos estacionarios.

Modelos

Se considerarán los siguientes tres modelos:

Modelo de Auto.Arima

Un acercamiento básico con el que podemos tener una idea inicial de la estructura del modelo es bajo comandos básicos de **auto.arima**, este modelo es solamente un acercamiento para construir modelos mas complejos (que eventualmente considerarán el uso de estacionariedad). Para ello, ejecutamos el siguiente comando:

```
auto.arima(serie)
```

```
Series: serie
ARIMA(1,1,5) with drift
```

Coefficients:

	ar1	ma1	ma2	ma3	ma4	ma5	drift
	0.3395	-0.3675	-0.7412	-0.4175	0.1752	0.3885	0.1570
s.e.	0.1084	0.1117	0.1051	0.0833	0.1023	0.0549	0.0149

```
sigma^2 = 14.79: log likelihood = -659.57  
AIC=1335.14 AICc=1335.77 BIC=1362.96
```

```
m.auto = Arima(serie,  
               order = c(5,1,0))  
summary(m.auto)
```

Series: serie

ARIMA(5,1,0)

Coefficients:

	ar1	ar2	ar3	ar4	ar5
	0.0691	-0.4006	-0.4786	-0.3408	0.0228
s.e.	0.0659	0.0622	0.0591	0.0619	0.0659

```
sigma^2 = 12.32: log likelihood = -638.22  
AIC=1288.43 AICc=1288.79 BIC=1309.29
```

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.2834614	3.465477	2.765534	0.2038429	3.426882	0.4902736

ACF1

Training set -0.005354872

Este comando arroja dos posibles modelos, pero en el desarrollo del trabajo notamos que acercamientos donde se tomaban en cuenta solamente términos autorregresivos presentaban mejores resultados a la hora de pasar a modelos estacionarios. De esta forma, nos quedamos con el modelo ARIMA(5,1,0). Note que en este modelo solamente los términos autorregresivos de orden 2, 3, y 4 se muestran como estadísticamente significativos para una significancia de $\alpha = 0.05$ (es decir, asumiendo un $z_{0.975} \approx 1.96$). Procedemos a revisar los supuestos:

Autocorrelacion de Resíduos

```
Box.test(m.auto$residuals)
```

Box-Pierce test


data: m.auto\$residuals

X-squared = 0.0068819, df = 1, p-value = 0.9339


En el que no existe una autocorrelación significativa para los residuales. No aplicamos un lag de 12 meses ya que este supuesto no hace parte de la estimación del modelo. Revisando los gráficos ACF y PACF de los residuales:

```
par(mfrow = c(1,2))  
acf(m.auto$residuals)  
pacf(m.auto$residuals)
```

Series m.auto\$residuals



Series m.auto\$residuals



Se concluye que este modelo tal vez no sea un buen acercamiento capturando el comportamiento de la serie.

Normalidad

```
shapiro.test(m.auto$residuals)
```

Shapiro-Wilk normality test

data: m.auto\$residuals

W = 0.99422, p-value = 0.4893

```
jarque.bera.test(m.auto$residuals)
```

Jarque Bera Test

data: m.auto\$residuals

X-squared = 1.9794, df = 2, p-value = 0.3717

Por lo que no rechazamos normalidad de los residuos de este modelo.

Homocedasticidad (ARCH)

```
ArchTest(m.auto$residuals)
```


ARCH LM-test; Null hypothesis: no ARCH effects

data: m.auto\$residuals

Chi-squared = 37.11, df = 12, p-value = 0.0002144

Con la que se puede rechazar la hipótesis de homocedasticidad. Verificando con una graficación de los residuales:

```
plot(m.auto$residuals)
```



Se puede notar que efectivamente la varianza no es constante a lo largo de los residuales estimados. Esto muestra que el modelo no debería ser tomado en cuenta mas allá que como una primera aproximación sobre el comportamiento de los datos.


Ajuste

```
ajuste1 = fitted(m.auto) # valores ajustados

df = data.frame(
  tiempo = time(serie),
  real = as.numeric(serie),
  ajuste = as.numeric(ajuste1)
)





ggplot(df, aes(x = tiempo)) +
  geom_line(aes(y = real), color = "black") +
  geom_line(aes(y = ajuste), color = "blue") +
  ggtitle("Datos reales vs Ajuste del modelo") +
  ylab("Producción Eléctrica") +
  xlab("Meses")
```

Datos reales vs Ajuste del modelo



Otra verificación sobre el comportamiento del modelo es comparar su ACF y PACF con el de la serie original. De esta manera:

```
par(mfrow = c(2,2))
acf(ajuste1, main = "ACF Modelo")
pacf(ajuste1, main = "PACF Modelo")
acf(serie, main = "ACF Serie Original")
pacf(serie, main = "PACF Serie Original")
```


ACF Modelo**PACF Modelo****ACF Serie Original****PACF Serie Original**

Se puede ver en el PACF que pasado el cuarto rezago el modelo empieza a presentar fallas con respecto a la estimación. En cambio, en el ACF se presenta un comportamiento bastante similar.

Modelo Estacional

Tomando en cuenta los resultados anteriores, consideramos que un modelo con estacionalidad de 12 meses podría resolver la mayoría de los problemas que este tiene. Dada la significancia de los rezagos en el PACF, se tomará también en cuenta un rezago de observaciones de orden 4. De esta forma:

```
serie = ts(serie, frequency = 12)
```

```
m.est = arima(serie,
               order = c(4,1,0),
               seasonal = list(order = c(0,1,1), period = 12))
summary(m.est)
```

Call:

```
arima(x = serie, order = c(4, 1, 0), seasonal = list(order = c(0, 1, 1), period = 12))
```

Coefficients:

ar1	ar2	ar3	ar4	sma1
-0.2635	-0.3229	-0.1869	-0.1799	-0.7292

```
s.e.    0.0660    0.0671    0.0694    0.0679    0.0540
```

```
sigma^2 estimated as 3.776:  log likelihood = -477.63,  aic = 965.25
```

Training set error measures:

```
      ME RMSE MAE MPE MAPE  
Training set NaN  NaN NaN NaN  NaN
```

Note que las métricas de entrenamiento no se muestran, de todas formas vamos a calcular manualmente RMSE y MAE (por ser a las que más estamos familiarizados) al final del documento en el apartado de selección de modelos. Procedemos a verificar los residuos con sus supuestos:

Autocorrelacion

Ya que este modelo tiene un componente estacional, debemos agregar un lag de 12 meses. Realizando la prueba de autocorrelación de los mismos:

```
Box.test(m.est$residuals, lag = 12)
```


Box-Pierce test

```
data:  m.est$residuals  
X-squared = 15.457, df = 12, p-value = 0.2174
```


Se puede concluir que no existe una autocorrelación significativa de los residuos en este modelo. Revisando los gráficos ACF y PACF de los residuales:

```
par(mfrow = c(1,2))  
acf(m.est$residuals)  
pacf(m.est$residuals)
```

Series m.est\$residuals



Series m.est\$residuals



Se ve que mejora bastante comparado con los del modelo anterior. La significancia de esta autocorrelación es bastante baja, y guiándonos por el estadístico de la prueba Box, es prudente considerar que los residuales no tienen autocorrelación significativa.

Normalidad

```
shapiro.test(m.est$residuals)
```

Shapiro-Wilk normality test

```
data: m.est$residuals  
W = 0.99253, p-value = 0.2675
```

```
jarque.bera.test(m.est$residuals)
```

Jarque Bera Test

```
data: m.est$residuals  
X-squared = 0.94527, df = 2, p-value = 0.6234
```

No rechazamos normalidad de los residuos de este modelo.

Homocedasticidad (ARCH)

```
ArchTest(m.est$residuals)
```


ARCH LM-test; Null hypothesis: no ARCH effects

data: m.est\$residuals

Chi-squared = 11.239, df = 12, p-value = 0.5085

Con esta prueba se puede ver que este modelo es homocedástico, y verificando con el gráfico de residuales:

```
plot(m.est$residuals)
```



Es difícil tener certeza sobre este resultado, pero dada la significancia de la prueba podemos confiar en la misma.

Ajuste

```
ajuste2 = fitted(m.est) # valores ajustados
```

```
df = data.frame(
```

```


tiempo = time(serie),
real    = as.numeric(serie),
ajuste  = as.numeric(ajuste2)
)

ggplot(df, aes(x = tiempo)) +
  geom_line(aes(y = real), color = "black") +
  geom_line(aes(y = ajuste), color = "blue") +
  ggtitle("Datos reales vs Ajuste del modelo") +
  ylab("Producción Eléctrica") +
  xlab("Meses")

```

Don't know how to automatically pick scale for object of type <ts>. Defaulting to continuous.

Datos reales vs Ajuste del modelo







Este modelo parece ajustarse mejor al anterior. Verificando con los diagramas de autocorrelación:

```

par(mfrow = c(2,2))
acf(ajuste2, main = "ACF Modelo")
pacf(ajuste2, main = "PACF Modelo")
acf(serie, main = "ACF Serie Original")
pacf(serie, main = "PACF Serie Original")

```

ACF Modelo**PACF Modelo****ACF Serie Original****PACF Serie Original**

Se notará mediante el PACF que adicionar un componente estacional brinda una mejor estimación para estos datos.

Modelo Estacional con Logaritmo

A pesar de que el modelo anterior se muestre bastante sólido, también deben considerarse acercamientos que puedan estabilizar la varianza de las series; un método de ello es aplicarles logaritmo. De esta manera procedemos con este modelo:

```
serieL = ts(log(serie), frequency = 12)
m.est.log1 = arima(serieL,
                    order = c(4,1,0),
                    seasonal = list(order = c(0,1,1), period = 12))
summary(m.est.log1)
```

Call:

```
arima(x = serieL, order = c(4, 1, 0), seasonal = list(order = c(0, 1, 1), period = 12))
```

Coefficients:

	ar1	ar2	ar3	ar4	sma1
	-0.2765	-0.2817	-0.1308	-0.1207	-0.8186
s.e.	0.0663	0.0696	0.0685	0.0673	0.0556

sigma^2 estimated as 0.0004914: log likelihood = 535.8, aic = -1061.61

Training set error measures:

```
      ME RMSE MAE MPE MAPE
Training set NaN  NaN NaN NaN  NaN
```

Se puede notar que los términos autorregresivos de orden 3 y 4 ya no son significativos, pero el término de primer orden en este caso sí lo es. Dado que estos datos corresponden a grandes escalas de producción, es un poco ingenuo considerar que el índice en cuestión se pueda ver afectado por cambios relacionados al mes anterior. Cambiando el modelo por uno mas simple:

```
serieL = ts(log(serie), frequency = 12)
m.est.log = arima(serieL,
                  order = c(2,1,0),
                  seasonal = list(order = c(0,1,1), period = 12))
summary(m.est.log)
```

Call:

```
arima(x = serieL, order = c(2, 1, 0), seasonal = list(order = c(0, 1, 1), period = 12))
```

Coefficients:

```
      ar1      ar2      sma1
-0.2415 -0.2279 -0.8186
s.e.    0.0651   0.0663   0.0549
```

sigma^2 estimated as 0.0005036: log likelihood = 533.07, aic = -1060.14

Training set error measures:

```
      ME RMSE MAE MPE MAPE
Training set NaN  NaN NaN NaN  NaN
```

Se ve que el AIC y log-verosimilitud se han reducido ligeramente. Procedemos a realizar un test de verosimilitudes para verificar si hay diferencias significativas entre ambos modelos. Como no encontramos una función que nos compare mediante MLE, decidimos crear una prueba bajo el supuesto de que esta diferencia de verosimilitudes sigue una distribución chi cuadrado.

```
lrt = 2 * (logLik(m.est.log1) - logLik(m.est.log))
(p = pchisq(lrt,
            df = attr(logLik(m.est.log1),
                       "df") - attr(logLik(m.est.log), "df"), lower.tail = FALSE))
```

'log Lik.' 0.06504657 (df=6)

Por lo que encontramos que no existen diferencias significativas entre ambos modelos para un $\alpha = 0.05$, pero al ser este valor p tan bajo, no tener términos significativos de mayor orden, y buscar un modelo parsimonioso, decidimos quedarnos con el segundo modelo.

Autocorrelacion

```
Box.test(m.est.log$residuals, lag = 12)
```

Box-Pierce test


data: m.est.log\$residuals

X-squared = 21.755, df = 12, p-value = 0.04036


Bajo logaritmo podemos rechazar la hipótesis de no autocorrelación en los residuales. Revisando los gráficos ACF y PACF de los residuales:

```
par(mfrow = c(1,2))  
acf(m.est.log$residuals)  
pacf(m.est.log$residuals)
```

Series m.est.log\$residuals



Series m.est.log\$residuals



Se ve que los residuales muestran una autocorrelación mas significativa que el anterior modelo, confirmando el resultado de la prueba Box.

Normalidad


```
shapiro.test(m.est.log$residuals)
```

Shapiro-Wilk normality test

```
data: m.est.log$residuals  
W = 0.99392, p-value = 0.4424
```

```
jarque.bera.test(m.est.log$residuals)
```

Jarque Bera Test

```
data: m.est.log$residuals  
X-squared = 0.40621, df = 2, p-value = 0.8162
```

Sigue sin rechazarse la normalidad en los residuos de los modelos estacionales.

Homocedasticidad (ARCH)


```
ArchTest(m.est.log$residuals)
```

ARCH LM-test; Null hypothesis: no ARCH effects

```
data: m.est.log$residuals  
Chi-squared = 12.749, df = 12, p-value = 0.3876
```

Con este test se puede ver que la homocedasticidad de los residuales se mantiene. Revisando la graficación de estos:

```
plot(m.est.log$residuals)
```



Se puede ver que hay ciertos valles donde la serie en efecto sigue teniendo una varianza explicable por el tiempo pero es mucho mas estable comparada con la del anterior modelo, por lo que tomar logaritmo fue una decisión acertada.

Ajuste


```
ajuste3 = fitted(m.est.log) # valores ajustados

df = data.frame(
  tiempo = time(serie),
  real    = as.numeric(log(serie)),
  ajuste  = as.numeric(ajuste3)
)

ggplot(df, aes(x = tiempo)) +
  geom_line(aes(y = real), color = "black") +
  geom_line(aes(y = ajuste), color = "blue") +
  ggtitle("Datos reales vs Ajuste del modelo") +
  ylab("Producción Eléctrica (Logaritmo)") +
  xlab("Meses")
```

Don't know how to automatically pick scale for object of type <ts>. Defaulting to continuous.


Datos reales vs Ajuste del modelo




No parece haber una mejoría respecto al anterior, y revisando los autocorrelogramas:

```
par(mfrow = c(2,2))
acf(ajuste3, main = "ACF Modelo")
pacf(ajuste3, main = "PACF Modelo")
acf(serie, main = "ACF Serie Original")
pacf(serie, main = "PACF Serie Original")
```


ACF Modelo




PACF Modelo



ACF Serie Original



PACF Serie Original




Se puede concluir que el modelo sin logaritmo parecía tener mejor PACF que este.

Pronóstico

Modelo de Auto.Arima

Don't know how to automatically pick scale for object of type <ts>. Defaulting to continuous.


Pronóstico auto.ARIMA



Modelo SARIMA

Don't know how to automatically pick scale for object of type <ts>. Defaulting to continuous.


Pronóstico SARIMA



Modelo SARIMA con Logaritmo

Don't know how to automatically pick scale for object of type <ts>. Defaulting to continuous.

Pronóstico SARIMA con Logaritmo



Selección e Interpretación del Modelo

Selección

Mediante la siguiente tabla de métricas:

	RMSE	MAE	AIC	BIC	LL
Modelo bajo función auto.arima()	3.465477	2.765534	1288.4303	1309.2891	-638.2152
Modelo SARIMA	1.889949	1.446212	967.2524	987.8021	-477.6262
Modelo SARIMA con Logaritmo	1.022085	1.017059	1058.1441	1044.4443	-533.0720

Podemos concluir que un acercamiento estacionario es el más acertado en métricas de error. El modelo estacional con logaritmo muestra las mejores métricas de error, pero note que se saltaba un supuesto y no respondía igual de bien en el PACF al modelo estacional. A pesar de su mejor precisión y mayor verosimilitud, decidimos quedarnos con el segundo modelo.

Interpretación

El comportamiento del índice de energía estadounidense entre 1985 y 2005 está determinada por el siguiente modelo:

$$\text{ARIMA}(4, 1, 0) \times (0, 1, 1)_{12}$$

Es decir que este índice, muestra que existe un ciclo presente en el desarrollo anual de la economía de este país; donde los cambios absolutos (presentes mediante la diferenciación) se ven explicados según los cuatro períodos inmediatamente anteriores al actual. Es de notarse que al ser estos términos negativos, se podría concluir que los cambios económicos se ven muy amortiguados mes a mes; es decir, aumentos o reducciones significativas en este índice siempre irán seguidos de una reducción o aumento (respectivamente) en la siguiente medición, teniendo efecto durante cuatro períodos seguidos.

A su vez, los cambios presentes de año a año señalan que el ruido estacional viene explicado por el año anterior, tal vez compensando cambios inesperados (shocks) entre ambos períodos de tiempo. Lo que indica que la economía es estable mes a mes pero no de año a año; en otras palabras, los cambios económicos a gran escala se notarán de forma significativa pasados períodos extensos de tiempo.

Referencias

- Board of Governors of the Federal Reserve System. (n.d.). *Industrial Production: Electric and Gas Utilities (NAICS 2211,2) [IPG2211A2N]*. FRED, Federal Reserve Bank of St. Louis.
<https://fred.stlouisfed.org/data/IPG2211A2N>
- Federal Reserve Board. (n.d.). *Industrial Production and Capacity Utilization: Methodology*.
<https://www.federalreserve.gov/releases/g17/Meth/MethIP.html>
- Investopedia. (n.d.). *Cyclical industry*. https://www.investopedia.com/terms/c/cyclical_industry.asp
- Federal Reserve Bank of St. Louis. (s.f.). *Industrial Production: Electric Power Generation, Transmission, and Distribution (IPG2211A2N)*. FRED, Federal Reserve Bank of St. Louis.
<https://fred.stlouisfed.org/series/IPG2211A2N>